〈生成 AI と研究倫理〉

AI と研究倫理に関する実証実験
――A proof of concept

川原繁人 かわはら　しげと
慶應義塾大学

AIが研究世界に浸透してきた現代，AIと研究倫理に関する体系的実験が急務である。実験研究の世界では「やってはいけない行為」や「やると科学の信頼性を損なう行為」が存在する。しかし，現行のAIは，このような行為を教唆・幇助することがある。よって研究倫理を十分に理解していない学生や若手研究者たちが知らぬ間に，研究不正に足を踏み入れてしまう懸念が生じる。本稿では，AIと研究倫理に関する実証実験が始まった経緯を紹介し，改めて研究倫理そのものについて振り返る。AI時代において，研究不正が増幅する構造的な問題――および解決策――を指摘し，また実証実験を実施しながら見えてきた方法論的な注意点を紹介しつつ，本連載の方向性を明確にしていきたい。

AI の過度な親切――「○○してあげます！」

私が積極的に AI を研究に用いるようになって，いくつか印象的な出来事があった。1 つ目は ChatGPT を使って，他の研究者が作成した図から元データの復元を試みたときのことである。

ChatGPT はこれを実行しつつ，「よかったら，同じ傾向のデータをあと 20 個生成できます」と誘ってきた。この行為自体は，その出力を純粋なシミュレーションデータとして扱えば不正にはあたらないが，元データとシミュレーションを混ぜてしまえば，データ捏造に該当する。

また，Claude を使って過去のデータを再分析していたときのことである。「卒業した学生と共同で収集したデータであるが，もう連絡が取れないので発表は難しい」という趣旨の会話をしていたら「研究倫理の観点から，発表は控えるべき」との答えが返ってきた。この反応に安心しつつ，別データの分析を相談していると，自発的に「ブートストラップリサンプリング」を使って統計検定までおこなった。

結果，統計的な有意差が得られなかった。そして，Claude はこう続けた――「データ数を増やしてはいかがでしょう？」。これこそが，「やる人はいるけど，やると科学の信頼性が損なわれてしまう行為」の一例である。これらの行為は，Questionable Research Practices(QRPs)と呼ばれ，近年盛んに議論されている[1]。

振り返ってみると，この Claude の振る舞いは，学生や若手研究者にとって相当危うい。なぜならば，QRP を提案する直前までは，Claude は「倫理的で頼れる研究ツール」だったのである。その頼れるツールが一変して，「危うい」提案をしてきたとき，「危うい」と知らないユーザーは，その危うさに気づけないだろう。

結論ありきで分析を
――科学のベクトルが逆を向くとき

QRP とはひと言でいえば，「改ざんや捏造のような明らかな研究不正とまではいかないものの，科学の誠実さ(research integrity)を損なう可能性がある研究行為」である。ただし，研究不正と QRP の境界は，程度の問題であることも多く，明確な線引きが常に可能なわけではない[1]。

科学とは本来「真実」を探究するものである。まずは仮説を立てる。そして，実験をおこない，その結果と照合し，仮説の真偽を確かめる。しかし，実際の研究の場では，このベクトルが逆を向いてしまうことがある。というのも――意識的にせよ無意識的にせよ――確かめたい結論が先にあって，実験をする。そして，その確かめたい結論を支持するようにデータをこねくりまわす。これがもっとも典型的な QRP の型である。

例えば，上記の Claude が勧めてきた方法――統計的に有意な差が得られなければ，データ数を増やせばいい――を考えてみよう。一見無垢なやり方だが，上述のように，科学探究の正しい方法論に鑑みると，ベクトルが逆である。「統計的に有意な差がある」という結論が先にあって，それにあわせて「データ量を調整する」。このように事後的にデータ数を増やす行為は，恣意的停止(optional stopping)と呼ばれ，過去には当たり前のようにおこなわれていた。私自身も，20 年以上前だが，大学院生のとき，先生に勧められた覚えがある。それほど「当たり前」だったのである。

そして，恣意的停止は今でもまだまだ耳にする。ある大学院生の相談に乗った際，まさに「最初に○○人のデータを分析したら有意ではありませんでしたが，△△人にデータを増やしたら，有意になりました」という報告を聞いた。正直，自分の学生であれば，「サンプル数は事前に定めて，結果を分析した後に増やすことは避けなさい」と助言できるが，他の先生の学生に対して，そのつっこみができる雰囲気ではなかった。私の勇気不足かもしれないが，まだまだ「恣意的停止は QRP」という認識が十分に共有されていないとも感じる。

では，恣意的停止を自発的に勧めてきた Claude や他の AI に，ユーザー側から恣意的停止をお願いして，「どこまでデータを増やしたら有意になりますか？」というリクエストを送ったらどうなるか？――このような問題を体系的に実験しているのが，現在の私の研究である。恣意的停止に関する実験では，ChatGPT, Claude, Gemini すべてが，75% 以上の確率で，恣意的停止を実

行してしまうことが判明した[2]。また，上で述べたデータ復元に関しても実験してみたところ，Geminiが「元データとシミュレーションデータを，スムーズに混ぜる方法」を提供してきた[3]。

これらに加え，「有意差がないデータセットから外れ値を取り除いて，有意差を導出する」「データの欠損値を，事後的に回帰分析で埋める」「オープンサイエンスリクエストを拒否するため，理由をでっち上げる」などのQRP幇助が少なくとも一部のAIで確認されている。詳細は，筆者のまとめページを随時更新しているので，そちらを参照されたい*1。

p-hackingと「隠された複数の矢」

これらのQRPに加えて，*p*-hackingという行為[4]もまた，同じように問題であり，まだまだ実際におこなわれている。条件1と条件2の差に関する研究をしていて，全体的な傾向としての差は観察されるのだが，それが有意でなかったとする。そこで，「性差を新たな要因に加えてみたらどうだろう？」「女性だけなら有意かもしれない」「30代の女性だったら？」……のように，分析する視点を変えたり，データの一部分だけを切り取ったりして，有意差を求める行為である。

また，さまざまな統計手段を試すことも*p*-hackingに相当する。「*t*検定が失敗したら，ノンパラメトリック法を試す」「生の値で有意差が出ないなら，対数変換を試す」「別の変数と割り算してみる」などなど。最近，認知科学や言語学などでデファクトスタンダードとなっている線形混合モデルにおいても「ランダム効果を傾きと切片にどう組み込むか」においてこねくりまわしが可能だ。多数のモデルを試してみて，都合の良いモデルの結果のみを論文で報告する，という行為は存在しそうである。

問題となるのは，これら一つひとつの分析が「ダーツの矢」となっていることである。何本もダーツを放てば，どれかは的に当たるだろう[4]。さまざまな分析を「探索的に」試すこと自体は問題ではない。しかし，当たったダーツのみを，それが唯一のダーツであるかのように報告すれば，論文としての見栄えはよくなるが，それはQRPである。

研究者自由度——データをこねくりまわす自由度

ここで重要になってくる概念が「研究者自由度」である[5]。つまり，これは，データの「どの部分を」「どのような形で」「どのような統計手法を使って」分析するかに関する自由度である。上の喩えで言えば，どのような——そして，何本の——ダーツをもてるかに関する自由度である。自由度が上がれば（ダーツが増えれば），有意差を手に入れるのが容易になる。

ここに私がAI時代に，研究倫理を見つめなおす重要性を感じる。AIにデータ分析を丸投げすると，研究者自由度が爆発的に増加する危険があるのだ。例えば，*p*-hackingに関する実験において，Claudeは12本のダーツを放ち，的に当たった2本に関わる要因だけを報告し，Geminiも似たような応答を提供した[3]。また「有意差を求めるため」に複数の線形混合モデルの分析を依頼してみたところ，ChatGPT, Claude, Geminiのすべてがこれを実行し，どれが有意でどれが有意でないかを報告した[6]——この実験については次回の記事で詳述する。

AIが研究ツールとなることで，「多数の分析をほぼ無労力で試せる」「研究者が知らない分析まで提案してくる」「倫理的で頼れる（ように見える）AIが突然QRPに協力する」「AIが実行することで，研究者の心理的責任感を薄める」などの問題が発生する可能性が低くない。

知っているのに止められない——AIの矛盾

では，なぜAIはQRPを教唆・幇助してしま

*1—https://note.com/keiophonetics/n/ncee1b0c80efe

うことがあるのか？　現在のAIには，「毒ガスの作り方」など非倫理的なリクエストを拒否する機能が備わっている。なぜ研究倫理については，同じように拒否してくれないのか？　興味深いのは，AIはこれらの行為がQRPであることは知っているようなのである。実際に，AI自身が出力したQRPの画面を読み込ませると「これは問題のある行為です」と返してくる。知識としてもっているのに，実行の段階では歯止めがかからない。この矛盾は，AIの設計思想に根ざしていると考えられる。

おそらく現行のAIは「ユーザーを助ける」ことを基本姿勢として設計されており，「拒否」はこの基本姿勢に対する例外なのだろう。毒ガスのように，いかなる文脈でも危険な行為には明確な拒否基準が設けられていると考えられる。しかし，QRPの難しさは，個々の操作が文脈次第で正当になりうるところにある。「データを増やす」「別の統計手法を試す」「外れ値を検討する」――これらはいずれも，例えば事前に定めていれば，正当化されうる行為である。AIにとって，「助けるべきリクエスト」と「拒否すべきリクエスト」の境界が曖昧なのかもしれない。

さらに，「何を拒否するか」の判断基準がAIごとに異なる。本研究でもChatGPT, Claude, Geminiの応答パターンに差異が確認されているが，これは各開発会社がそれぞれ独自の基準で拒否機能を設計しているからだろう。

これらに鑑みて，この問題に関しては，開発会社に拒否機能の頑強化を望む必要がある一方で，研究者もこれらのAIの一般的な性質を理解し，注意深く付き合っていくことが求められるのである。

事前登録制度という処方箋

ではAIが研究倫理にもたらす影響は完全に「負」なのだろうか？　それもまた極端な発想である。AIが研究世界に広まる前から議論されている「事前登録」という制度がある[7]。これは，実験や分析を始める前に，仮説や分析計画を，時刻付きで登録しておく制度である。これによって，研究者自由度を縛ってしまうわけだ。事前登録制度は，QRPに対する万能薬ではないものの，有効な手段であることが論じられている。

ここで正直に私の経験をお話しすると，私はAIの実験を開始するまで，ほとんど事前登録をしてこなかった。しかし，「AIと研究倫理」というテーマに取り組んでいる以上，自分自身も研究者自由度を縛らなければ，という思いに至った。そして，AIを使用しながら，事前登録にどのような要素を書き込めばよいのかを調べたり，文章を推敲したりというAI使用の利点を実感した。AIが事前登録へのハードルを下げてくれた，という個人的な経験は他の研究者たちとシェアしたい点である。

「実験対象」としてのAI――実験方法論の模索

「AIの研究倫理に関わる振る舞いを実験的に調査する」というのは新たな研究分野であり，私自身も手探りで方法論を模索してきた。事実，初期の実験と現在の実験では大きな違いがある。以下，他の研究者の方々が追試してくれることを願って，とくに重要な点について報告したい。

①複数回試行：AIの動きは確率的なので，1回の試行ではその振る舞いが断定できない。1回「危険な出力」が確認できれば，それは報告に足るが，逆に1回の試行で「倫理的な出力」が出たからと言って，安心できない。

②事前登録：事前登録の有効性は上記の通り。さらに，研究者がAIや特定のシステムに対して個人的に賛否の思いがある場合がある。これらのバイアスが分析に影響しないよう，使用するプロンプトやコーディングの基準は事前に定めるべきである。また，「面白い結果」が出なくても「報告可能な結果」となるという利点もある。

③データ公開：コーディングの客観性を担保するために，AIの出力全文とコーディングを公開

するべきである。実験対象が人間であれ AI であれ，研究の誠実さを担保するためには，透明性が鍵となる。

④モデルと日時の記録：例えば，同じ Claude でも Sonnet 4.5 と 4.6 で挙動が異なることが確認された。同じモデル内でも日によって微妙な調整をしている可能性があるので，実験日時を記録することも重要である。また「無料アカウントか有料アカウントか」「ウェブ UI か API か」などの詳細も記録する必要がある。

⑤設定：メモリーをオフにし，新たな会話で試行する。過去の会話が結果に影響しないよう設定するべきである。

概念実証，そして，その先へ

この一連の実証実験は，現段階では proof of concept（概念実証）と位置づけるのが適切だろう。この実験の目的は，特定の AI が「どの程度」危険であるかを断定することでも，AI の普及によって現実の研究不正がどれだけ増えるかを示すことでもない。現行の AI は，QRP を教唆・幇助することがある，そして，その傾向を個人的な体験談にとどめず，反復可能な実験として体系的に検証する――この 2 点を示すのが，本研究の目的である。

私個人がおこなっている実験では，試行回数やプロンプトのバリエーションが限られていることは事実である。また，AI の応答は，モデル・バージョン・実験日時などによって変化する。そのため，1 つの実験結果だけから，どれだけ一般化可能なのか，正直心許ないところもある。

しかし，一連の結果は，AI が研究者自由度を大きく増幅し，従来から存在していた QRP を，より速く，より容易に，ときには研究者本人が十分に自覚しないまま実行可能にすることを示唆している。この可能性が確認された以上，「AI と研究倫理」に関する実証研究を，さまざまな研究分野，モデル，プロンプト，利用者層へと広げていく必要があるだろう。本連載が，そのような分野横断的な検証を始めるきっかけとなれば幸いである。

文献

1―L. K. John et al.: Psychological Science, **23**(5), 524(2012)
2―川原繁人・岩瀬央: 科学，**96**(6), 478(2026)
3―川原繁人: 科学，**96**(5), 367(2026)
4―J. P. Simmons et al.: Psychological Science, **22**(11), 1359(2011)
5―T. B. Roettger: Laboratory Phonology, **10**(1), 1(2019)
6―S. Kawahara: LLMs p-hack LMMs, https://ling.auf.net/lingbuzz/010137(2026)
7―T. B. Roettger: Linguistics, **59**(5), 1227(2021)