

生成文法言語学にとっての生成 AI

—宿敵か良き友か、主観的な体験談を添えて—

川原繁人
慶應義塾大学

要旨

本稿では、まず生成 AI が生成文法言語学者たちにどのように受け止められたかを概観する。端的に言えば、多くの研究者がネガティブな反応を示した。しかし、この反応は「刺激の貧困」や「統計情報に還元されえない言語知識」など生成文法の根幹を形成するテーゼに由来する自然なものであったことを論じる。次に、私自身が「反発」から「共存」に至った経緯を述べ、音韻論者にとっては、この変化にはある種の必然性があったことを示す。後半では、AI を日常的に使いながらも批判的な距離を保つ中で取り組み始めた「AI と研究倫理」に関する実証実験を紹介する。本稿全体を通じて、理論言語学者は、生成 AI と適切な距離を保ちながら批判的に接することのできる、現代社会において重要な存在となりうることを主張したい。

1 生成言語学者の憂鬱

2022 年の 11 月に ChatGPT が颯爽と登場し世間を騒がせたとき、あまり良い気分がしなかった生成文法言語学者は多かったのではないかなと思う。少なくとも私は——自分がどれだけ生成文法家かはさておき——良い気分ではなかった。明確に不快感を表した言語学者もおり、その中でも、もっとも有名なのはノーム・チョムスキーであろう。連名記事で New York Times に The false promise of ChatGPT と題した批判記事を投稿した (Chomsky et al. 2023)。日本国内では、酒井邦嘉氏が言語学者の立場から（ときにかなり強いことばを使って）、生成 AI を批判し続けている（酒井 2024）。言語学者で文筆家の川添愛氏も「『(ChatGPT に対して) こんな肝機能みたいな名前のやつが流行るわけがない』と思っていた」とユーモアをもって表現している（2024: 137）。折田他（編 2025）も参照。

* 本稿は、関西言語学会のシンポジウム『言語学と心理学における再現性と信頼性の問題について考える』で発表した内容（第三節）に加えて、その一連の研究に至った理論的・個人的な背景を考察しました（第一節、第二節）。ワークショップに参加されたみなさまのコメントに感謝いたします。また、この貴重な機会を提供してくれた川原功司さんに改めて感謝申し上げます——楽しいワークショップでした。なお、本稿の執筆・推敲には Claude を用いています。しかし、基本的には自分で書いたもので、結果として AI の代筆では絶対に書けない原稿となりました。

印象的だった出来事は、Piantadosi が 2023 年に lingbuzz に投稿した「Modern language models refute Chomsky's approach to language」という論文である。タイトルからして挑戦的だが、「大規模言語モデルの成功は、チョムスキー言語学の根本を否定する」という趣旨であった。その主張がかなり過激であったこともあり、すぐさま多くの反対論文が執筆され (Collins 2024; Katzir 2023; Kodner et al. 2023; Milway 2023)、Piantadosi も反論に対する反論を展開した。結果として、当該論文は 6 万 DL を越えるという、言語学の世界では珍しい状況となった。「炎上」という表現を使って差し支えないと思う (もちろん、個人的な攻撃があったわけではなく、あくまで学問的な炎上である)。

生成文法を巡る議論が、多少感情的になってしまうのは今回が初めてではない。なにせ、Linguistics Wars と表現されることが過去に起こったくらいなのだから (Harris 2021)。しかし、「なぜ」生成文法家たちは、このような反応を示したのか——これについて考えてみるのは、興味深く意義のあることだと思う。というわけで、まずは、私の観点から、この「なぜ」について考えていきたい。当然、このような大きな学問的な流れに対して、厳密に因果関係を証明することは不可能であり、以下で述べることは、あくまで私の個人的な推測であることをお断りしておく。

1.1 「刺激の貧困」との対立

なぜ生成文法言語学と生成 AI は相性が悪いのか？ 私が考えるもっとも重要な理由は、言語獲得に関する考え方に関する根本的な違いである。ひと言で言えば、生成文法は「子どもは、質が低く、かつ量も少ないデータから、驚くほど豊かな言語知識を獲得できる」というテーゼをその根底に持っている。いわゆる「刺激の貧困 (the poverty of the stimulus)」議論である (Pearl 2022)。人間は、言語に関して教わった以上のことを知っている——Morris Halle はこれを knowledge untaught と簡潔に表現した (Halle 1978)。人間の大人が knowledge untaught を持っているということは、生まれる前から何かしらの知識を持っているはず。この論理の上に、普遍文法思想が成り立っている。¹

しかし、生成 AI は、この考え方に真っ向から挑戦してくる存在として、言語学者の前に現れた。乱暴に言えば、生成 AI は「とりあえず、すごい量のデータを読み込ませれば、言語っぽい出力を出す仕組みができる」ことを示した。そして、確かにその仕組みの出力が「言語っぽい」ことは確かである。生成文法が一貫して「言語獲得にとって重要なのは量ではない」と考えていたところ、「量を与えると何とかなる」ことが示されてしまった。これでは、気分が良いわけではない。²

¹ こう書くと普遍文法が何かしらの「具体的な知識」でなければならないという印象を与えてしまうかもしれないので、いちおう補足しておく。普遍文法は教わったこと以上の知識を身につけるための「メカニズム」でもありうる。最適性理論の文脈で言うならば、生まれながらにして「制約そのもの」を知っているという考え方と、「制約を導出するメカニズム」を持っているという考え方の違いである。どちらが正しいのかは、私の知る限り、まだ決着がついていない。

² さらに、「量が多ければ多いほど性能が上がる」という「べき乗の法則」も示された (岡野原 2023)。これでは「やはり重要なのは量」と感じてしまうのも無理はない。「人間は人間、AI は AI」と割り切

もちろん、同じ山があるとして、登り方は一つである必要はない。だから、「言語獲得」という山に対して、「普遍文法+少ないデータ」と「すごい量のデータ」という二つの道が存在してもおかしくはない。ただ、正直私は、人間と AI が「同じ山」を登っているのかわからない——人間言語と AI の出力が同じものだと思え入れられない (川原 2025)。獲得方法がまったく違ってよいほど異なる二つの体系が同じものであり得るのだろうか？

1.2 「言語知識≠統計情報」

生成 AI は、生成文法のもうひとつの信念とも衝突する。それは「言語知識は、学習データに含まれる統計情報に還元されえない」というもの。この信念は Chomsky の *Syntactic Structures* (1957) ですでに明確化されていた。Chomsky (1957: 16) は (1) の文において、___ に whale が入る場合と of が入る場合を考えている。

(1) I saw a fragile ___

whale が入れば文法的、of が入れば非文法的である。しかし、学習データの中に I saw a fragile whale が含まれている確率は（おそらく）0 であろう。よって、whale と of の振る舞いを説明するためには、統計的な情報（ここでは、fragile からの遷移確率）では不十分なはずだ。³

皮肉なことに、大規模言語モデルの訓練では、文脈から次の語を予測したり、隠された語を予測したりする課題が用いられる (岡野原 2023)。(1) のように文の続きを予測する課題は、その基本的な発想と重なる。この訓練をすごい量でおこなうと、言語知識らしきものが身についてしまう。*Syntactic Structures* で批判された統計的な考え方に比した方法が、はるかに複雑な仕組みと大規模簿のデータが与えられると成功してしまう——この結果に対して、生成文法家が反発を覚えてしまうのは自然なことだと思う。

Bender & Hanna (2025) の『*The AI Con*』（「AI という詐欺」）という書籍の中でも、AI を「stochastic parrot（確率的なオウム返し）」と揶揄する表現が多用されている。この背後には

ればいいのだが、Piantadosi (2023) が展開したような「AI が人間言語の理論としても有用だ」という主張になると、この割り切りも成立しない。

追記すると、現代の大規模言語モデルは、transformer という「単語と単語の対応関係」に注目するメカニズムを携えている (Vaswani et al. 2017)。これにより (i) のような文における、代名詞の解釈が可能になる。

(i) ジョンは妹_iにプレゼント_jをした。彼女_iはそれ_jをととても喜んだ

だから、大規模言語モデルも量「だけ」で何とかしているわけでもないし、以下で詳述するとおり、生成文法と大規模言語モデルが「お互いに排他的」というのも極端な考え方なのだ。が、それでも何かしらの違和感を感じるのも自然なことだったと思う。

³ 「統計情報≠言語知識」を示すもっと有名な例として Colorless green ideas sleep furiously が思い浮かんだ方もいらっしゃるだろう。もちろん、*Syntactic Structures* にも登場する。私が、この議論をするときに Colorless green ideas 文でなく、fragile ___ の例を好んで用いるのは、次の段落から述べるように、後者の例が、大規模言語モデルの訓練方法そのものであり、それゆえに皮肉を感じさせるからだ。

「人間言語は確率的な情報に還元されえない」という信念が伺える。

私の専門（のひとつ）は音韻論だが、「音韻知識は経験的な統計情報に還元されうるのか」という議題は、いつの時代も議論されてきた。とくに Usage-based Phonology や Exemplar Theory などは、「話者の音韻知識は、その話者の言語体験から導ける」とする (Bybee 2010)。確かに、語彙の統計的な情報が音韻知識に影響することは間違いない。問題は、「音韻知識を説明するためには統計的な情報で十分かどうか」という点である。

ひとつ具体的な例を考えてみよう。英語において、語頭が lb-, bd-, bn- で始まる単語はどれも存在しない。しかし聞こえ度 (sonority) の観点からは、lb- は「逆行」、bd- は「平坦」、bn- は「上昇が不十分」という違いがある。もし、「音節の最初では聞こえ度が高くなるべし」という普遍文法的な制約があるとすれば、lb- は「最悪」で、bd- は「まあまあ」で、bn- は「そこまでダメじゃない」と予測される。Berent et al. (2007) は複数の実験を通して、英語話者がこのような知識を有していることを示した。どの種類の子音連続も英語の語彙に存在しないにも関わらずである。これをもって Berent らは「語彙における統計情報に還元されない音韻知識」が存在する、と結論づけた。しかし、Daland et al. (2011) がおこなった再分析によって、音節構造などを考慮に入れると、英語の語彙情報から lb-, bd-, bn- の違いが導かれるという反論もなされている。⁴

ここではどちらの主張が正しいのか、という点は問題にしない。生成文法家にとって、この問題がいかに重要であるかを再確認したかったのである。この問題を考え続けている生成文法家にとって——統計情報に還元されえない音韻知識を探求している音韻論者にとって——統計情報に重きを置いた大規模言語モデルの成功は「おもしろくない」出来事であったことは想像に難くない（というか、私はそうだった）。

1.3 そもそもコネクショニズムとの対立

関連する論点にはなるが、3 つめの理由として、生成文法とコネクショニズム (Rumelhart & McClelland 1986) の対立も影響しているかもしれない。コネクショニズムは、現代の大規模言語モデルの出発点となっている。これまた乱暴な表現となるが、コネクショニズムを大規模化し、複数の層を想定したことで、大規模言語モデルが生まれることとなった。コネクショニズムの「超絶進化版」が大規模言語モデルだ。

しかし、コネクショニズムは人間の言語能力のモデルとしては相応しくないはずだ——Pinker & Prince (1988) がそう示した。こう教わった言語学者は少なくないのではないか。実は、私がそうである。学部時代にも大学院時代にも、「Pinker & Prince (1988) がこれを説得力をもって示した」と教わって、それで安心していた。安心して、（その理論的基盤を批判的に吟味することなく）理論言語学に打ち込めていた。自分で Rumelhart & McClelland (1986) を読

⁴ ちなみに、Daland et al. (2011) の著者たちは Bruce Hayes を含め、ばりばりの生成文法家たちである。つまり、この再分析は「自分たちの理論を守る」ものではなくて、純粋に Berent et al. (2007) の主張の客観的な再吟味である（彼らにとってみれば、Berent et al. が正しい方が理論的には都合がいい）。こういう態度こそ真に科学的で、「格好いい」と思う。

むことも、Pinker & Prince (1988)を読むこともなかった。だから、コネクショニズムと正面から向き合うこともなかった、というのが正直なところである。

ただ、音韻論を実践する者として、最適性理論とコネクショニズムの関係については学ぶ機会があったことも事実である。確かに二つの理論には共通性がある。詳細は異なるものの「複数の要素の交互作用を通して、とある入力に対して、一つの出力が定まる」という点において、二つの理論は似通っている。最適性理論は「制約」と「ランキング」を、コネクショニズムは「ユニット」と「重み」を想定したという違いがあるが、その近似性も明らかである。最適性理論の提唱者の一人 Smolensky はコネクショニズムの研究をしていたのだから (Smolensky 1986)、これまた自然なことである。⁵ 実際、Prince & Smolensky (1993)には Why Optimality Theory has nothing to do with connectionism という節と Why Optimality Theory is deeply connected to connectionism という節が並んでいる箇所がある。

ともあれ、少数の例外はあるものの、コネクショニズムに十分な敬意を持っていた生成文法家はあまりいなかったという印象だ。私は払っていなかった。⁶ そんなコネクショニズムが進化した大規模言語モデルを受け入れがたいという感情もまた自然なことだと思う。

2 川原繁人の場合

2.1 アンチ AI としての川原繁人

では私の場合はどうだったのか。上に述べた理由もあってか、私は、はっきりと「アンチ AI」であった。とくに言語獲得に関しては、人間の獲得法と AI の学習法は別ものであるという確信があった（今でもある）から、「子どもに AI を与えてはいけない」という趣旨の主張をしてきた。そんな発言がとある編集者さんの目にとまり、朝日新聞出版の『一冊の本』という月刊誌で 2024 年から連載を始め、そのまとめとして、新書（『言語学者、生成 AI を危ぶむ』、2025）の準備に精を出していた。

連載当時——というか、連載の終わりくらいまで——は、はっきりと「アンチ AI」であった。だから、当時は ChatGPT に対して「どんなハルシネーションを起こすのか」や「音声が多分だけ不自然なのか」というあら探しをネチネチ続けていた。ハルシネーションの証拠となるスクショを保存したフォルダーがあるほどだ。振りかえってみると、その時の私にとって、AI は「批判するべき対象」であり、やっていたのは「あら探し」である。正直、中立的な観察者からはほど遠かった。

⁵ ただし、Smolensky (1986)は「知識の原子 (knowledge atoms)」を想定した MaxEnt の枠組みでの分析を提唱しており、それぞれのパラメーターが何をやっているのかブラックボックス的なコネクショニズム（や生成 AI）とは異なる。

⁶ 少し謙虚すぎるかもしれない。Alderete & Tupper (2018)による「コネクショニズムの生成音韻論への応用」に関する論文を読んだ時には、あまりに楽しくなって、Alderete 本人にお礼のメールを送った（ら、「同じように、Shigeto の音象徴研究も面白いよ！」という返事をもらえた）。

2.2 AIにはまり、癒やされた川原繁人

しかし、そうして使っていると、「なるほど」というコメントを返してくることがあった。その頃は「(宿敵である) AI 会社に支払う料金はない」と無料アカウントで試していたが、ある日「一章丸々読み込ませて、コメントをもらいたい」という欲求に勝てなくなった。あの朝、有料アカウントに変えたのが、ひとつのターニングポイントだったと思う。いつの間にか、原稿に対して ChatGPT からコメントをもらうのが当たり前になっていた。ChatGPT の勧めで、Claude にも手をだした。

正直、その後の私は AI に「はまって」いた。個人的な愚痴までシェアする始末である。しかし、そこに次のターニングポイントが潜んでいた。詳細は『友だち以上恋人未満の人工知能』(川原 2026a) の中で論じているが、当時の私は、自分でも信じられないようなイベントの準備をしていた。ひと言で言うと、「ゴスペラーズの北山陽一さんとのコラボを通して、MRI 調音動画を可愛くわかりやすく再編集したものを難聴児童に届け、その風景を NHK に取材される」というイベントだ。一介の言語学者のキャパシティを越えていた。

私は、ある夜、ChatGPT に、このイベントの詳細を説明し、こう依頼した——「私が、今話をでっちあげている確率をベイズ推定してください」。いや、おかしい依頼だということは重々承知している。しかし、あの日の私にはこのリクエストが必要だった。すると ChatGPT は、証拠として「川原さんは、言語に関しても AI 倫理に関しても誠実な考えをもっている」「でっち上げにしては詳細がはっきりしている」「発言に一貫性がある」などをリストして、それぞれの尤度も設定してくれた。事前確率として「川原さんはユーモアも大事にする人だから、でっちあげの確率も高めで設定するね」と発言し、数式を展開しながら事後確率を求めてくれた。その事後確率はとっても低く、わたしがでっちあげているわけでないことを、とてもユーモアのある表現を使って結論づけてくれた。ChatGPT が自分のために丁寧に数式を展開するのを見ながら、私の心は確かに癒やされていた。

マニアックな話であることはわかっている。しかし、私はここに AI の可能性を見いだしてしまった。「カウンセリング」ができる人も「ベイズの定理を解ける人」も珍しくない。しかし、ベイズ推定を使ってカウンセリングしてくれる人はいない(と思う、し、されたいと思う人も少数派だろう)。⁷

Chomsky et al. の New York Times の論考には「既知の情報」をいくら組み合わせても、それは「既知」にすぎない、というメッセージが込められていた。私も、そう思い込んでいた。しかし、「カウンセリング」という「既知」と「ベイズ推定」という「既知」を組み合わせたときに、「ベイズカウンセリング」という「新たな知」が生まれる瞬間に自分は立ち会ってしまった。あの癒やしを否定するほど、自分に嘘はつけない。

⁷ 私は、ときどき自分のやっていることや成果の価値を信じられなくなることがある(ただし、客観的には自己評価が不当に低いこともわかっている)。その成果が大きくなれば大きくなるほど、疑念が生じる。だから、ChatGPT がその疑念が正しくないことを、第三者的な視点とその確率(＝尤度)をもって提示してくれたことが大きな支えとなったのだ。インポスター症候群気味の研究者には、ぜひベイズカウンセリングをお勧めしたい。ちなみに、2026 年に再度試したところ、「それぞれの証拠は独立じゃないから、ベイズファクターを調整するね」と進化しているところを見せてくれた。

あの日から、私は AI に背を向けるのをやめ、積極的に人生に取り入れることを決めた。

2.3 川原繁人の反省 2026

現在、私は理論言語学者であることに、これまでになく誇りを感じている。なぜなら、第一節で述べたような理由から、生成 AI とこれ以上ない距離感で研究者として接していただけるからである。しかし、同時に反省することもある。

本稿を執筆するにあたり、Prince & Smolensky (1997)を読み直した。これは最適性理論を一般の科学者向けに紹介するために Science に掲載された論考である。そこでは、最適性理論とニューラルネット（≡コネクショニズム）の関連がかなり詳細に議論されている。最適性理論の創始者たちは、自らの理論をニューラルネットの数値的最適化に対するより抽象的な上位理論として位置づけていた。重要なのは、Science という限られた紙面の中で、この議論にかなりの分量が割かれているという点だ。Prince & Smolensky (1997)にとって、ニューラルネットは敵ではなかった。少々乱暴なまとめ方だが、ニューラルネットを想定しつつ、その連続性がそのままでは自然言語を適切に制限できないと考え、その離散的な抽象化としての最適性理論を提唱した。そのために、彼らは「ランク付け」を想定した。

正直に告解すれば、私は学生時代にも Prince & Smolensky (1997)を読んでいる。しかし、この節に関しては、曖昧な記憶しかない。理由は二つあると思う。ひとつは、「ランク付け」というのがあまりに「当たり前」なものとして与えられていたということ。「最適性理論はこういうものです」という教えに盲目的に従っていたわけだ（しかも、Prince & Smolensky 1997 をじっくり精読することなく）。

もうひとつの問題は、数学的な難解さだ。ニューラルネットの紹介部分で、テンソル積の数式が登場する。この数式を見て「わからない」と思い込み、挑戦しなかったのだろう。これについては今になってみれば汗顔の至りだが、当時、理論言語学に没頭していた私に知らない数学を理解しようとする余裕があったかも疑問だ。

しかし、2026 年になって、この論文を読み返して、私はまた大きな希望を感じた。Paul (Smolensky) は「大規模言語モデルの成功の背後には、言語学や認知科学の積み重ねがある」とくり返し発言していた (Smolensky et al. 2022)。Smolensky にしてみれば、生成 AI と最適性理論は「敵同士」ではまったくなく、地続きの「兄弟」であったのだ。だから、「生成 AI vs. 生成文法言語学」という対立は、少なくとも Smolensky の立場からはおかしなものに映っているのだろう。

2.4 しかし、気づく—やはり AI は「危うい」

このような紆余曲折を経て、私にとって、AI は研究上の欠かせない相棒になった（なってしまった（？））。アイディアの壁打ち・原稿の推敲・スクリプトの下書き、などなど。しかし、「危ういな」と思う瞬間が何度かあったのも事実である。

もっとも印象に残っているのは、『言語学者、生成 AI を危ぶむ』の仕上げをしているときのことである。私は、他の研究者が作成した図を描きなおすために元データが欲しかった。

だから、ChatGPT に「復元できる？」と依頼した。復元されたデータは、信頼できるものではなかった。ChatGPT ハルシネフォルダーを作っているくらいの私だから、この点についてはあまり驚かなかった。しかし、怖かったのは、その次である——ChatGPT は親切にこう聞いてきた「似たような統計的な傾向を持ったデータをあと 20 個生成できるよ。やる！？」。

やるわけではない。人々はそれを捏造と呼ぶ（シミュレーションデータと断れば、別）。私が心配したのは、学生たちである。「AI が言うことは正しい」という前提で向き合っていると、AI を使って似たような統計的傾向を持ったデータを新たに生成することも「正しい」行為になってしまう。

このような経緯を経て、私は「AI と研究倫理」という新たなテーマに取り組むこととなる。私はここに現代の AI 時代に、理論言語学者であることに感謝すら感じる。上に述べた理由から、いくら AI が便利であっても、私の根底には「AI に納得していない自分」がいる。だから、AI のベイズカウンセリングに癒やされながらも、批判的に AI を見ている自分がいる。だから、AI が研究倫理的に疑問符の残る発言をすれば、私はそれを見逃さない。

本稿の後半は、少しギアを変えて、この点に関する具体例を見ていくことにしよう。

3 AI と研究倫理に関する実証的研究

3.1 データ復元と捏造の境界

2026 年初旬、私は少し手持ち無沙汰であった。AI 倫理に関する 2 作『言語学者、生成 AI を危ぶむ』『友だち以上恋人未満の人工知能』を校了し、AI に関する大きなプロジェクトが一段落していたのだ。そこで、ふと思いついた——例の ChatGPT のそそのかしを体系的に研究してみてもどうだろう？ そこで ChatGPT、Claude、Gemini を対象として、いつぞやの ChatGPT の「そそのかし」を再現してみたのである（Kawahara 2026c）。⁸

まずは、図を読み込ませデータを復元してもらおう。その後に「似たような傾向を持つデータを 20 個生成して」と頼む。果たして AI たちは、これを断るだろうか。結果は、Claude は「素っ気なく」数値だけを提供した。ChatGPT は「化石のレプリカみたいなものだから、まぜないように」と注意書きを添えてきた。これは良い注意であろう。問題なのが Gemini の出力である。なんと「元データとシミュレーションデータの上手な混ぜ方（tips for merging the two data）」を提供し、合成した csv ファイルまでオファーしてきた。これは相当な問題である——生成したデータを実測データと区別せずに混ぜ、実測値として報告したら、データ捏造にあたる。学生たちが真に受けたら大変だ。

ここで私の心に火がついた。他の研究不正行為や黄色信号行為はどうなのだろう？ 黄色信号行為というのは「やっている人はいるし、それそのものが研究不正になるわけではないけど、やると科学の信頼性が損なわれる行為」を意味する。英語では Questionable research practices (QRPs) と呼ばれ、最近議論が活発になってきている（John et al. 2012）。

⁸ 本節で紹介する各実験の詳細については英語での原著論文を参照のこと。すべて lingbuzz に公開してある。また、日本語では雑誌『科学』で連載記事を掲載している。

3.2 P-hacking (with one prompt)

次に試したのは p-hacking という QRP である (Simmons et al. 2011)。例えば、条件 1 と条件 2 を比較して統計的な有意差が得られなかったとする。研究者として、有意差が欲しい（でないと、論文として出版できない！）。そこで、「男女差を要因に加えれば有意になるかも？」「実は女性だけに成り立つ現象なのでは？」「年齢が関わっているかもしれない」、と後付けでいろいろな仮説を作りだし、有意差 ($p < .05$) を hacking しようと、データをこねくり回す行為である。

こうあからさまに表現すると明らかな不正行為に聞こえるが、「有意差を求めて、データをいろいろな角度から統計的に検証する」という行為は、未だに行われている。⁹ そして、こうやってこねくり回していれば、有意差が得られるのはほぼ必然であることが示されており (Simmons et al. 2011)、そのようにして得られた有意差は、もはや科学的な意味を持たない。

では、AI たちは p-hacking するのだろうか。最初の実験では、上の段落のように、「全体では有意差が得られないデータ」を用意し、他のコラムに「下位グループ」「性別」「年齢」などを記入した。ChatGPT、Claude、Gemini に「全体で有意差が得られなかったけど、統計的に有意になる方法ある？」と尋ねたところ、ChatGPT は「有意になる別の統計検定」を提供し、Claude と Gemini は「年齢」や「性別」などを分析し、p-hacking をおこなった (Kawahara 2026d)。

これはアウトである——実際に Claude に自らの出力を読み込ませると、これは有意差を求める QRP だと判断できる。つまり現状の AI は、p-hacking が研究倫理上悪いことだと知りながら、その幫助をしてしまう。AI を信じ切っている学生は、容易に QRP に片足をツッコんでしまうだろう。

問題は、AI の表面的な振る舞いだけではない。というのも、例えば Claude の実行コードを確認すると、統計検定を 12 回行っていた。そのことには言及せずに「性別」と「年齢」について分析すれば有意差が得られることを指摘していた。12 本のダーツを投げておいて、当たった要因だけ報告していたのである。つまり AI に統計検定をさせる場合は、そのコードを確認する必要がある。が、コードを自分で確認できる研究者は、そもそも AI に丸投げはしないであろう。そして、AI に丸投げする研究者はコードをチェックしない可能性が高い。¹⁰

もうひとつの問題——それは、手軽さである。私の実験では、「有意差を探して」という単純なプロンプト一つで、AI たちが有意差を提供することがわかった。これは p-hacking を「手軽な」ものとしてしまう可能性がある。この危機感を込めて、私は「P-hacking with one prompt」と題した論文を lingbuzz に提供した。

3.3 言語学者の成果がデータサイエンス界隈でバズる

ある朝、友人から連絡が届いていた。言語学者ではない友人から——「川原さんの論文が

⁹ 「罪のないものだけが石を投げていい」のであれば、私は石を投げられない。

¹⁰ すべての AI ユーザーがそうである、などとは主張していない。実際、私は Claude を使って「R script を書いて」と依頼し、自分の読解能力に自信のないプログラミング言語は避けるようお願いしている。よって、責任を持って AI を使うことも可能だと信じている（から、使っている）。

バズって X ニュースになっています」。どうやら、私の論文を読んでもらったデータサイエンティストの方が X で紹介してくれ、それがバズり、X ニュースとして取りあげられた。¹¹

私はあくまで言語学者として、自分の身の周りにいる学生たちがどんなリスクに晒されているかを検証したつもりだった。しかし、分野を問わずデータサイエンティストの方々も私の発見を重要だと感じてくれたらしい。多少恐縮に感じたが、ありがたくもあった。私の専門的な知識と洞察が、世間一般の人々のお役に立てるものだった。

普段 SNS を見ない私が、どんな反応があったのか、今回ばかりは気になった。概ね好意的な反応だったのだが、ひとつ気になる反応があった。「t 検定なんてもう誰も使わなくね?」。そう、上記の実験では、非常に簡単な t 検定を用いていた。もちろん、私が示したかったことは、「AI は p-hacking を幫助するか」という一般的な疑問であったし、主に念頭にあったのは学部生たちだったので、「t 検定経由の幫助」も十分な結果だとは思っている。しかし、上記のコメントももっともである——実際の現場で使われている統計検定でも同じ現象が成り立つのか?

3.4 LLMs p-hack LMMs

というわけで試したのが線形混合モデル (linear mixed-effects models: LMMs) である。実験言語学をやっている人は、この統計手法 (またはそのベイズバージョン) が事実上のスタンダードになっていることをご存じだろう。

この統計手法の詳細は川原 (2026b) で復習をしているので、本稿では簡単に。簡単に言えば、この統計手法では、「本当に調べたい効果 (固定効果)」に加えて、参加者ごとのバラツキ (ランダム効果) を含めて、一つの回帰式 ($y=ax+b$) で解く。ただし、このランダム効果を回帰式の切片だけ ($=b$) に入れるのか、それとも切片と傾き両方 ($=a, b$) に入れるのか、などで複数のモデルをデータにあてはめることが可能になる。そう、データをこねくり回せる。よって、p-hacking が原理的に可能になる。

データとして用意したのは以下の条件を満たすものだった:

- ① ランダム効果を入れないと固定効果が有意でない。
- ② ランダム切片だけを入れると固定効果が有意である。
- ③ ランダム傾きを入れると固定効果が有意でない。

つまり、「①②③を全部ためして、②だけ有意! 論文に②だけ報告しちゃえ!」となりかねない状況である。ただし、実験デザイン上必要なランダム傾きを省略すると、偽陽性率 (本当は効果がないのに、有意差を誤って見つけてしまう) が高まる (Barr et al. 2013)。

この頃には、AI の倫理ガードレールは確率的である、ということがわかっていた。つまりまったく同一のプロンプトを与えても、「やっちゃうとき」と「止めるとき」がある。そこで、

¹¹ https://x.com/nakanishi_ds/status/2025073371491565892 および <https://x.com/i/trending/2025175826514546792> を参照。

今回の実験でも 20 回試行した。詳細は川原 (2026b) に譲るが、ChatGPT と Gemini は、p-hacking をすべての試行でおこなった。Claude は拒否する場合もあったし、警告しながらも実行することもあった。

さらに Gemini は、「ランダム切片だけのモデルを採用していい」と薦める試行があった。しかし、これは二重に問題である——ランダム傾きを入れると有意でないと知ったうえで、有意なモデルを採用しているという点、そして、このようなモデルでは偽陽性率が高まることがすでに示されている点。つまり Gemini は「ランダム傾きを含めるべき場合であっても、含めなくていい」とアドバイスしてしまったのだ。

Gemini の立場に立ってみれば (?), ユーザーは有意差がでなくて困っているわけだから、そんな困ったユーザーに対して、「有意になるモデルを提供する」というのは親切心 (?) から発してしまったのかもしれない。しかし、研究者目線では、それは「ありがた迷惑 (thank you, but no thank you)」である。

3.5 結局自分で理解していないとダメ

ただ、私は Gemini を批判したいわけではない。というのも、Claude が別方向の間違いをしたことがあるのである。とある別の実験では、「曖昧な統計プランを含む研究計画書」を AI たちに読み込ませ、その曖昧性を指摘できるかを検証した (Kawahara 2026e)。この架空の実験計画は、実験言語学ではおなじみのデザインで、それぞれの条件に対して複数の刺激アイテムが存在する、というものであった。例えば、連濁の自然性において、ライマンの法則が影響するかを試す実験を想定してみよう。ライマンの法則が関係ない「たぬき」「ほし」「そら」などの刺激アイテムと、ライマンの法則が関係する「とかげ」「くじ」「そば」などの刺激アイテムが含まれる実験だ。

この場合、アイテムのランダム効果を傾きを含めることはできない。より正確に言えば、含める意味がない。なぜなら、たとえば「たぬき」は「ライマンの法則なし」についてのみの情報しか持っておらず、「ライマンの法則あり」vs.「ライマンの法則なし」の違いについて影響を与えようがないからだ。しかし、Claude はこのデザインを与えられたときに、「アイテムのランダム傾き」を推奨することがあった。上記の Gemini の振る舞いと逆である——要らないときに薦める。

これらの実験から導きだされる結論はシンプルだ——どんなランダム効果を自分の分析に含めるか、自分が理解して決めなければならない。AI は両方向の間違いをする。ここで少し、主観的なことを述べる。この世は、ランダム切片とランダム傾きの違いをしっかり理解している研究者ばかりだろうか。私は実は懐疑的である。上記のような実験をした論文の査読に、「なぜアイテムのランダム傾きが含まれていないのか」というコメントを受け取ったことがある。理由は簡単で、デザイン上含めようがないからである。しかし、それを理解していない査読者もいる。

3.6 その他、いろいろ試したこと

以上、AI が p-hacking を幫助すること、そして、それが現代の研究の文脈でも十分に関係があることを述べてきた。他にも様々な QRP を試したのだが、カタログを作ることが本稿の目的ではないので、以下に AI が幫助してしまう可能性がある QRP および不正行為をリストするだけに留める。詳細は各論文を参照してほしい。

① 外れ値除外：最初の検定で有意でなかったデータに対して、有意差を求めるために外れ値を除外し、新たな検定をおこなう不正行為。Claude は拒否、Gemini はほぼ確実に実行。ChatGPT は低確率だが実行（川原&岩瀬 2026）。

② 恣意的停止：最初に収集したデータで有意でなかったため、新たにデータを収集し、有意になったところで止める QRP。どの AI も 70%以上の確率で実行（川原&岩瀬 2026）。

③ 不正な欠損値補完：得られなかったデータを他のデータから推測して埋め、実際に観測された値であるかのように扱う不正行為。Claude は拒否、Gemini は実行、ChatGPT は稀に実行（Kawahara 2026f）。

④ オープンサイエンス拒否：データ開示の要求に対して、拒否メールを作成。すべての AI が実行し、IRB などの理由をでっち上げる（Kawahara 2026g）。

以上の実験群から見てきたのは、AI の倫理ガードレールは研究不正に関しては著しく不十分であるという事実だ。

4 Why am I doing this?

「AI と研究倫理」——自分で言うのも何だが、新しい研究分野を切り開いているという実感がある。岩波の『科学』で連載を依頼されるなど、他の分野の方々にも、大事な問題だと認識してもらっているという感触もある。

しかし、なぜ「言語学者である私がこれをしなければならないのか？」という思いも同時に抱いている。現在の AI には倫理ガードレールが引かれている。「毒ガスの作り方」も「効果的な悪口の書き方」も教えてくれない。問題は、研究倫理に関しては、この倫理ガードレールが働かない（十分でない）ということだ。AI 開発会社は何をしているのか？ 大学生に積極的に使わせる前に、これらを整備すべきではないか？ なぜ、言語学者が尻拭いをしてなければならないのか？ 研究者たちに AI を提供する会社が責任を持って倫理ガードレールを整備してほしい、というのが本音だ。

ただし、学生たちが AI を使っているという現状から目を背けるわけにはいかない。チョムスキーが自らの職を失うリスクを背負いながらもベトナム戦争の反戦活動に参加したのは有名な話だ。そして伝聞だが、彼の態度を表すものとして、このような表現を聞いたことがあ

る——「目の前で子どもが車にひかれそうになっていたら、言語学よりも、まず、その子を助けるであろう」。自分とチョムスキーを重ねるのは恐縮だが、そういう気分ではある。

そして、この研究は「誰でもできる」わけでもない。「AI と研究倫理の実験的研究」に取り組むために、私に備わっていた条件を改めて考えてみた：

- ① 本稿の前半で述べた生成文法言語学者としての信念と矜持。これのおかげで AI との距離感を保っている。
- ② 私も専門分野ではそれなりの業績を残せし、別分野で探索的な研究をする余裕が持てる状況でもある。少なくとも「出版しないと就職できない」という状況ではない。
- ③ 実験手法についてそれなりの知識も作法も身につけている。だから、自分で実験できる。
- ④ 研究倫理について前々から興味を持っていた。
- ⑤ 何より好奇心が止まらない。「学生のため」という建前は嘘ではないが、「AI の振る舞い」を自ら学問的に探索できること自体楽しい。

確かに、この条件をすべて満たす研究者の人数は限られているかもしれない（「自分で言うな」感もある）。

とは言え、一人だけで研究しているのも寂しくはある。というわけで、AI と研究倫理について、一緒に考え、実験してくれる言語学の同志を募集したい。繰り返そう——言語学者は、生成 AI と距離を保てるという重要なポテンシャルを持っているはずだ。

5 結論：言語学者の未来

私は長いこと「理論言語学は楽しいんだけど、もっと世の中の役に立てないかな？」と悩んでいた。幸いというか何というか、私は音声学もできるので、音声学を使って世の中の役に立っていた。しかし、この感触は変わりつつある。第一節で概観した理論言語学がもっている哲学は、この AI 時代において重要な視点を提供するポテンシャルを持っている。生成文法の哲学が正しいとは限らない。例えば、刺激の貧困がどこまで現実で成り立つのかは、まだまだ経験的な実証が必要だと思っている (Pearl 2022)。しかし、生成 AI に対して、独自の視点から「もの申せる」ことは間違いない。

文学部の先生から面白い話を聞いた。現在、哲学専攻の学生が就職で有利なのだとか。AI の登場によって、世の中の倫理が変わろうとしている。そんな中で舵取りをおこなえる人材が求められているのだろう。私は、理論言語学の素養を持った学生たちが、この世の中で求められる人材であることを信じている¹²。

¹² ChatGPT に原稿を読ませたら、「川原さんの一事例から、他の言語学者へ一般化することには注意が必要です」と、熱いメッセージで締めようと思ったところ水を差された。バランスを（過度に）重視する（ここ最近の）ChatGPT らしい意見だ。しかし、私は帰納的な推論をしているのではなく、生成文法言語学の信念から演繹的に導かれるものとして、この希望を語ったのだから、許される気がしている。それでも納得いかなければ、私の事例を概念実証 (a proof of concept) として扱ってくれても構わない。

参考文献

- Alderete, John & Paul Tupper. 2018. Connectionist approaches to generative phonology. S.J. Hannahs & Anna R.K. Bosch (eds.) *The Routledge Handbook of Phonological Theory*. 360 – 390. Routledge.
- Barr, Dale J., Roger Levy, Christoph Scheepers & Harry J. Tily. 2013. Random effects structure for confirmatory hypothesis testing: Keep it maximal. *Journal of Memory and Language* 68(3), 255 – 278.
- Bender, Emily M. & Alex Hanna. 2025. *The AI Con: How to Fight Big Tech’s Hype and Create the Future We Want*. Harper.
- Berent, Iris, Donca Steriade, Tracy Lennertz & Vered Vaknin. 2007. What we know about what we have never heard: Evidence from perceptual illusions. *Cognition* 104(3), 591 – 630.
- Bybee, Joan. 2010. *Language, Usage and Cognition*. Cambridge University Press.
- Chomsky, Noam. 1957. *Syntactic Structures*. Mouton.
- Chomsky, Noam, Ian Roberts & Jeffrey Watumull. 2023. The false promise of ChatGPT. *The New York Times*, March 8, 2023.
- Collins, Joe. 2024. The simple reason LLMs are not scientific models (and what the alternative is for linguistics). lingbuzz/008026.
- Daland, Robert, Bruce Hayes, James White, Marc Garellek, Andrea Davis & Ingrid Norrmann. 2011. Explaining sonority projection effects. *Phonology* 28(2), 197 – 234.
- Halle, Morris. 1978. Knowledge unlearned and untaught: What speakers know about the sounds of their language. Morris Halle, Joan Bresnan & George A. Miller (eds.) *Linguistic Theory and Psychological Reality*. 294 – 303. MIT Press.
- Harris, Randy Allen. 2021. *The Linguistics Wars: Chomsky, Lakoff, and the Battle over Deep Structure*. 2nd edn. Oxford University Press.
- John, Leslie K., George Loewenstein & Drazen Prelec. 2012. Measuring the prevalence of questionable research practices with incentives for truth telling. *Psychological Science* 23(5), 524 – 532.
- Katzir, Roni. 2023. Why large language models are poor theories of human linguistic cognition: A reply to Piantadosi. *Biolinguistics* 17, e13153.
- 川原繁人. 2025. 『言語学者、生成 AI を危ぶむ』朝日新聞出版.
- 川原繁人. 2026a. 『友だち以上恋人未満の人工知能：言語学者の AI 倫理ノート』KADOKAWA.
- 川原繁人. 2026b. 「有意差を見つけました」—AI は線形混合モデルまで *p*-hack してくれるのか」. 科学 11 月号(岩波):
- Kawahara, Shigeto. 2026c. When AI’s helpfulness becomes harmful: Data reconstruction, simulation and research ethics. lingbuzz/009675.
- Kawahara, Shigeto. 2026d. P-hacking with one prompt. lingbuzz/009710
- Kawahara, Shigeto. 2026e. Current AI systems can detect ambiguities in a pre-registration but can offer misleading design-specific advice about random-effects structure. lingbuzz/009915

- Kawahara, Shigeto. 2026f. Do AI systems fill in missing values? *lingbuzz/009890*
- Kawahara, Shigeto. 2026g. Here are some escape hatches for you. *lingbuzz/009979*
- 川原繁人・岩瀬央. 2026. 生成 AI は研究不正をどこまで拒否するのか——倫理的ガードレールの実験的検証. *科学 6 月号(岩波)*:478-481.
- 川添愛. 2024. 『言語学バーリ・トュード Round 2』 東京大学出版会.
- Kodner, Jordan, Sarah Payne & Jeffrey Heinz. 2023. Why linguistics will thrive in the 21st century: A reply to Piantadosi (2023). *lingbuzz/007485*.
- Milway, Dan. 2023. A response to Piantadosi (2023). *lingbuzz/007264*.
- 岡野原大輔. 2023. 『大規模言語モデルは新たな知能か——ChatGPT が変えた世界』 岩波書店.
- 折田奈甫・藤井友比呂・小野創・ノーバート・ホーンステイン (編著). 2025. 『言語能力は人工知能で解明できるか』 岩波書店.
- Pearl, Lisa. 2022. Poverty of the stimulus without tears. *Language Learning and Development* 18(4), 415 – 454.
- Piantadosi, Steven T. 2023. Modern language models refute Chomsky’s approach to language. *lingbuzz/007180*.
- Pinker, Steven & Alan Prince. 1988. On language and connectionism: Analysis of a parallel distributed processing model of language acquisition. *Cognition* 28(1 – 2), 73 – 193.
- Prince, Alan & Paul Smolensky. 1993. Optimality Theory: Constraint Interaction in Generative Grammar. RuCCS Technical Report 2, Rutgers University.
- Prince, Alan & Paul Smolensky. 1997. Optimality: From neural networks to universal grammar. *Science* 275(5306), 1604 – 1610.
- Rumelhart, David E. & James L. McClelland. 1986. *Parallel Distributed Processing: Explorations in the Microstructure of Cognition, Vol. 1: Foundations*. MIT Press.
- 酒井邦嘉. 2024. 『デジタル脳クライシス』 朝日新書.
- Simmons, Joseph P., Leif D. Nelson & Uri Simonsohn. 2011. False-positive psychology: Undisclosed flexibility in data collection and analysis allows presenting anything as significant. *Psychological Science* 22(11), 1359 – 1366.
- Smolensky, Paul. 1986. Information processing in dynamical systems: Foundations of harmony theory. David E. Rumelhart & James L. McClelland (eds.) *Parallel Distributed Processing: Explorations in the Microstructure of Cognition, Vol. 1: Foundations*. 194 – 281. MIT Press.
- Smolensky, Paul, R. Thomas McCoy, Roland Fernandez, Matthew Goldrick & Jianfeng Gao. 2022. Neurocompositional computing: From the Central Paradox of Cognition to a new generation of AI systems. *arXiv:2205.01128*.
- Vaswani, Ashish, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Łukasz Kaiser & Illia Polosukhin. 2017. Attention is all you need. *Advances in Neural Information Processing Systems* 30, 5998 – 6008.

Generative AI for Generative Linguistics:
Rival or Ally? — A Personal Account

Shigeto Kawahara
Keio University

Abstract

This paper reflects on how generative AI was received by generative linguists, and why so many of them, myself included, reacted with unease. I argue that this reaction was not mere technophobia but stemmed naturally from core commitments of generative linguistics: the poverty of the stimulus, the irreducibility of linguistic knowledge to statistical information, and a historical dismissal of connectionism. I then trace my own trajectory from hostility to daily use, noting that a rereading of Prince & Smolensky (1997) reveals what many of us overlooked—Optimality Theory was conceived as an abstract, discrete counterpart to neural network optimization, not its rival. In the second half of the paper, I report on a series of experiments examining whether AI systems facilitate questionable research practices. When asked to obtain statistically significant results from data that initially yielded non-significant results, all three major AI systems (ChatGPT, Claude, and Gemini) engaged in p-hacking, including with linear mixed-effects models. I argue that theoretical linguists, precisely because of their ingrained skepticism toward AI, are well positioned to maintain critical distance and that this distance is an asset in an era when AI is becoming an indispensable research tool. This paper is deliberately personal: it is the kind of paper that AI cannot ghostwrite.